

SafeConf 第一批模型决策结果

日期：2026-09-28 | 已完成结果 | 开发实验，非独立确认

1. 已经做完什么、现在的判断

第一批已完整结束：7 个数据组、3 个相关上游基线、552 个去重任务、1656 条预测记录、63 个外层比较单元。主比较共 945 次小模型拟合，另有 252 次幅度基础回归（含内部交叉拟合），得到 1071 行评价；训练用时约 **3 分 56 秒**。CPU 运行 Ridge/树，现有 cu124 环境在一张 RTX 6000 上运行小 MLP。批次结束已停止，没有追加第二批、重训上游或扩大网络。

事前协议提交：eealbfc。输入、标签、分组、模型配置、种子和调参预算没有按中途结果改变。运行中仅更正文字事实：旧目录存在，缺的是部分运行脚本/独立审计清单。详见 [模型决策](#) 与 [运行状态](#)。

我的判断是：可以继续做冻结上游模型的下游风险方法。当前最明确的信号来自历史支持/相关程度；公共历史内容的增量很不均匀。显式幅度锚定和更复杂网络都没有成为必需结构。

这支持继续构造计算方法，但还不支持宣布统一 SafeConf 已完成，或已经达到二区/CCF-B 的录用水平。当前已有方法证据和实验资产足以组织开题；最终论文还需要成熟上游、来源闭合和独立确认。

2. 三个 upstream predictor 到底是什么

上游预测器	实际规则	输出	本轮角色
PertMeanPredictor	原始上游训练库内，同扰动的真实效应取平均；无同扰动时用全局平均。生成 train 预测时排除自身任务	按基因排列的平均表达变化向量	均值转移基线
ContextSimBaseline	优先取同扰动、其他背景的历史效应；按对照状态余弦相似度 softmax 加权；没有来源时回退	同样的基因效应向量	背景相似性转移基线
V0StrongBaseline	有目标背景时， $0.85 \times$ 同扰动平均效应 + $0.15 \times$ 该背景平均效应；缺失项用相应回退	同样的基因效应向量	固定混合基线

它们共享相近的历史转移机制；名称含 Strong 不等于已经证明强于现代上游。**这三者不是 GEARS、scGPT、CPA，也不是三种基础大模型**。本轮学习的是这些预测的任务级 RMSE 风险。已有 GEARS/CPA/TxPert 等旧结果未在本轮重新训练，也未在未对齐输出空间时直接合并。

源码：[两种原始基线](#)、[PertMean](#) 及表生成。

3. 552 个任务如何分布，它们是不是全部论文数据

数据组	类型	去重任务	每种上游记录	三上游合计
Cui	基因	150	150	450
Frangieh	基因	76	76	228
Lara ex vivo	基因	38	38	114
Lara in vivo	基因	46	46	138
Santinha	基因	34	34	102
McFarland	化学	140	140	420
sciPlex3	化学	68	68	204
合计	基因 344 / 化学 208	552	552	1656

552 是不同任务键的数量，不代表 552 个独立同分布观测：同一扰动、背景与研究内存在相关性；同一任务的三种预测不能算三次独立生物实验。两个 Lara 分组也不能当两项完全独立研究。

这是当前避开已定位的原始 train 回流问题的开发子集，**不是未来论文总数据量，也不是已完成全流程血缘认证的最终干净测试集**。逐行旧产物与原始模型状态仍需核实。每个数据组/上游单独三折按扰动分组，fit 为 22-100 条，eval 为 11-50 条。外层任务、扰动均无交集，三上游使用相同任务折。未把它写成上游从没见过该扰动；上游训练库可以存在同扰动的其他背景。

4. 相同输入下，幅度锚定有没有必要

U20 表示：按风险最高的 20% 任务优先复核时，获得多少经完美排序归一化的收益。随机排序期望为 0，完美排序为 1；**0.8091 不是 80.91% 预测准确率，也不是发表概率**。

下表都先折平均，再预测器平均，再数据组等权；不按细胞数或表格行数加权。

风险模型	总体 U20	基因 U20	化学 U20
原始幅度直接排序	0.4759	0.4670	0.4980
仅幅度的非负线性基础风险	0.4398	0.4670	0.3718
直接 Ridge, P+Q+H	0.8091	0.8552	0.6938
幅度锚定残差 Ridge, 同样 P+Q+H	0.7740	0.8413	0.6057
直接梯度提升树, 同样 P+Q+H	0.7577	0.8047	0.6402
幅度锚定残差树, 同样 P+Q+H	0.7739	0.8273	0.6404
直接小 MLP, 同样 P+Q+H	0.7053	0.7873	0.5004
幅度锚定残差 MLP, 同样 P+Q+H	0.6710	0.7395	0.4997

同信息锚定的配对增量：Ridge **-0.0351**、树 **+0.0162**、MLP **-0.0343**。树有 4/7 数据组正向，Ridge 没有正向组（按数值容差，6 负、1 平），MLP 2/7 正向。

因此这批不支持“幅度必须是一个冻结残差分支”。幅度应继续作为核心基线和显式可见输入；**它信号强，不等于先拟合再相加的结构必然优于直接学习**。基础风险也未必优于原始幅度排序：有限样本中的零斜率或折间估计会造成退化。

5. 历史支持与历史内容各增加多少

本轮使用三个信息源中的前两个：

- 当前预测 P：幅度、绝对均值、两种预测间分歧，4 项。
- 公共历史 Q：背景相似度最大/均值、同扰动支持背景数，3 项；反映相关程度和覆盖，缺少完整细胞数与重复质量。
- 公共历史 H：历史参考幅度比较 2 项、跨背景真实效应稳定性/方差 2 项、固定历史均值转移残差 1 项，共 5 项。Q 与 H 同属公共实验历史。
- 模型错误记忆 E：本轮未训练，来源资格未通过，不能把它的增量填成零或用旧 E 代理替代。

同算法逐步加信息	Ridge ΔU_{20}	树 ΔU_{20}	小 MLP ΔU_{20}
学习 M $\rightarrow$ 纯 P	+0.0967	+0.1854	+0.0968
P $\rightarrow$ P+Q	+0.2362	+0.1657	+0.1931
P+Q $\rightarrow$ P+Q+H	+0.0527	+0.0299	-0.0172

第一行使用各算法自己的 M-only 学习器，不能误读为都比“原始幅度排序”增加同样多。相对原始幅度，直接 P 的增量分别为 Ridge +0.0444、树 +0.0863、MLP +0.0536。完整表见 [RESULT_TABLE.md](#)。

Q 的方向较一致：三种算法各有 6/7 数据组正向。但这只能称“支持/相关程度代理有效”，不能直接称测量质量因果效应。

H 的总体均值掩盖很强异质性：


- Ridge 的基因平均增量 **-0.0080**，化学平均 **+0.2044**。
- 主要正增量来自 McFarland (Ridge **+0.4423**)；另一化学组 sciPlex3 为 **-0.0335**。
- 仅作描述，剔除 McFarland 后其余六组 Ridge 平均为 **-0.0123**。主结果始终保留全部七组；不能据此挑选数据。
- Ridge 和树的 H 都只有 3/7 数据组正向。因此既不能宣布“公共历史普遍有效”，也不能宣布“公共历史无用”。

尤其要注意：H 还不是我们最终想要的公共历史表达。两个历史幅度字段与 M 存在确定性关系；标准化后的幅度比在同一源 fold 内可以成为 M 的重复缩放，加入 Ridge 还可能改变有效正则强度。旧稳定性/方差又混合生物异质性与测量误差。**本批 H 增量不能直接解释为独立生物历史内容增量。**这正是下一阶段必须先重新定义字段的原因。

后续应怎样定义干净

信息	应包含	应避免混入
当前预测	固定基因空间中的预测 RMS、形状、稀疏度、可获得的分歧	历史真实幅度归一化、当前真实响应
公共历史质量/支持	来源数、细胞数、重复数、相容背景/条件覆盖、split-half/重复一致性与缺失标记	把效应方向相似或方差全部解释成技术质量
公共历史真实内容	来源实验真实效应方向、强度、通路变化、预测与来源效应的差异；另标历史尺度参考	当前任务 treated truth；任意上游自己的错误
模型错误记忆	同一冻结模型对既有未训练任务的误差/交叉拟合剩余误差	生物历史均值转移误差冒充某模型反馈

公共历史内容可进一步区分“历史尺度参考”和“生物响应内容”，二者仍是同一个信息源的子类。先去重复、补完整 Q，再估计 H 的条件增量，才有资格决定它在最终模型中的作用。此处是字段设计与后续建议，本轮没有重构原始矩阵或追加训练。



固定模型比较与历史内容分组增量

6. Ridge、树、小 MLP 哪个更稳定；第一版究竟选什么

同 P+Q+H 条件下，Ridge 总体比树 +0.0514、比 MLP +0.1038，两个比较各有 5/7 数据组正向。63 个折/预测器比较单元中，Ridge 对树为 24 正/23 负/16 平，对 MLP 为 25 正/10 负/28 平；这些单元相关，不能作为独立样本做显著性宣传。

本批只有一个固定随机种子和配置，没有证明训练随机性稳定或全调参空间最优。我们能说的是：当前很小的样本下，增加非线性容量没有带来一致收益，Ridge 的总体结果更好。

- 当前开发参考实现：直接 Ridge，P+Q+H，24 维输入（12 值+12 缺失标记）、25 个数/截距参数。它是本批参考成绩，不是最终 SafeConf 定型。
- P+Q 的 Ridge（14 维输入、15 参数）必须保留为强而简单的对照，因基因线路加旧 H 后平均退化。不能事后按哪种类型胜出就部署两套，而不再验证这种选择规则。

- 小 MLP 为 24→16→8→1、545 参数；锚定版连同基础风险 547 参数。当前没有证据要求十万参数、Transformer 或复杂门控。
- 显式锚定继续保留为方法假设/负结果，不写成已验证创新。若最终统一模型成立，应由跨数据、跨成熟上游的冻结验证支持。

论文真正可研究的对象是“哪些历史能在控制当前预测和支持后改进风险，何时应退回简单预测信息”；残差分支只是其中一种可被否定的实现。**单独的 Ridge 第一名不等于已经贡献了一篇新的计算方法论文。**

7. 哪些旧结果或说法需要撤回

旧结果/解释	本轮处置	不应扩大解释为
E273/E274 的新风险折完全未见，因此上游也未见任务	撤回。源表 train 被上游用于拟合；重切风险折没有撤销该使用	所有历史实验全无价值
E273 的六项 P 完全不含公共历史	撤回。幅度比/偏离使用了历史真实效应尺度	预测向量自身不能做风险
旧 train 行的 H/E 是正式无泄漏泛化证据	不可继续用于这个主张。全局历史统计可能包含该 train 任务，自身标签排除也未证明上游 OOF	已观察的数值被修改或删除
E274 E=0 等于零目标模型错误标签；曲线说明只更新记忆即可	撤回。每档仍用全部 fit 标签重训	记忆机制已被证明无效
7 个数据组都是基因扰动或七项独立研究	纠正为 5 个基因分组、2 个化学分组，Lara 两分支相关	基因+化学覆盖不存在
E201 幅度很强；E258/E259 完整 Q 后旧 H 弱化	本轮没有推翻这些结论，保留原证据级别与负结果	新 552 子集替代全部正式研究

应撤回的是“正式无泄漏泛化”“完全预测侧”“合法反馈”等不成立解释；原始文件、参数、旧分数和失败门继续保留供审计。不应拿本批 0.8091 与旧 0.7413/0.7493 相减：来源、样本、特征分类、标签目标和汇总方式已经不同。

8. 3668 个任务最多能恢复多少

只读取 dataset/task_key/predictor/fold/split 元数据，未读取其他折的标签或表达，也没有重新生成预测。

数据组	当前任务	所有折 val 去重候选	可新增 val 候选	包含其他折 test 角色的理论候选上限
Cui	150	493	343	1002
Frangieh	76	231	155	507
Lara ex vivo	38	127	89	259
Lara in vivo	46	144	98	301
McFarland	140	456	316	930

数据组	当前任务	所有折 val 去重候选	可新增 val 候选	包含其他折 test 角色的理论候选上限
Santinha	34	107	73	218
sciPlex3	68	206	138	451
合计	552	1764	1212	3668

因此：

1. **优先恢复空间是 1764 个任务，其中比本批多 1212 个。** 它们已经有 val 角色记录，可优先核对现有产物，无需先重训大模型。
2. 在这 3668 个任务范围内，元数据层面每个任务在某个折都有 held-out 角色；另外 **1904 个**只在 test 角色中补齐。**3668 是候选上限，不是已恢复合法数量。** 看到 test 元数据不等于允许使用封存真值；已经公开的旧测试材料也不能再称未见最终确认集。
3. 不同原始折对应不同上游训练集合/模型状态，不能全拼成一个冻结模型的 Error Memory。应保留模型版本和原始折，并在风险切分中对同任务、同扰动及相关研究隔离。其他折模型可能训练过当前目标任务，也需按用途审计。
4. 当前本轮额外确认的**正式合法任务仍为 0**；1764/3668 是待审计候选。公开旧表最多能扩开发集，不能靠重新命名变成新的独立确认集。
5. 如果状态血缘无法恢复，才考虑用已有任务级效应缓存重建小基线 OOF；是否需要重训 GEARS/CPA 取决于它们实际的训练日志与预测产物。本轮没有启动。

计数见 [RECOVERABLE_TASKS.csv](#)、[RECOVERY_STATUS.json](#)；候选任务键已另存压缩表，不包含误差标签。

9. 什么时候能交付，9 月 30 日能讲到哪里

本批计算、结果表、模型决策和恢复数量分析现已完成。 已有 [完整进展与开题材料](#)；本报告是应补充进去的最新结果，不能用之前报告中的预期代替它。

后续若启动下一阶段，我对工作量的估计是：现有产物的恢复审计约 2-4 小时；可恢复旧基线的来源与字段整理再需半天左右，若必须重建预测则需先小样计时。这是工作量估计，**不是已经启动的后台任务，也不能保证这些候选全部通过审核。** 强上游验证与独立确认不能承诺在 9 月 30 日前闭合。

9 月 30 日进展/开题可完整交代：问题定义、三类信息来源、已有正负证据、这批同条件对照、旧结论修正、可恢复数据量、后续可证伪路线。可以展示方法假设与实证推导，不应宣称已经完成投稿论文的全部有效性验证。

目标刊可继续参考 TCBB：CCF 官方目录将其列入 B 类，期刊范围覆盖生物问题驱动算法、数学和统计方法；这说明方向契合，不说明当前工作已满足录用要求。“二区”还需按学校使用的具体分区体系与年份核对，本报告不把它与 CCF-B 画等号。[CCF 目录](#)、[TCBB 官方范围](#)。

10. 复现与停止记录

- 运行脚本：[run_safeconf_model_decision.py](#)。已完成目录拒绝覆盖，复现应使用单独 checkout/输出位置，避免抹掉本批记录。

- 结果文件：RESULTS.csv、DATASET_RESULTS.csv、PAIRED_COMPARISONS.csv、完整数值表。任务级输出为 PREDICTIONS.csv.gz；各折来源和任务哈希均保存。
- 回归 RMSE 只在同数据组、同折、同上游内比较；CSV 中跨数据组原始 RMSE 的简单平均不是统一生物尺度。原始幅度不是预计误差，所以其回归 RMSE 为空。
- 4 项实现检查通过：不解析禁止行标签；query 真值不能改变特征/基础风险；内部交叉拟合排除自身扰动标签；并列风险的随机期望效用正确。另核对 63 个单元的样本一致性与三上游折一致性。
- 输入与运行脚本哈希、软件版本、GPU、运行时间和终态在 RUN_STATUS.json；结果汇总核对在 SUMMARY_AUDIT.json。当前文档有事实更正，运行时协议哈希对应事前提交 eea1bfc。
- 新上游训练：0；最终测试标签使用：0；新增大规模预处理：0；完成后追加训练：0。停止状态：COMPLETE_STOPPED_AFTER_FIRST_BATCH。