

面向单细胞扰动预测的幅度锚定与证据增量风险评估方法研究

开题报告与研究进展底稿 | 2026-09-28

用途：2026 年 9 月 30 日导师/学校汇报。文中分别标明已完成结果、提出的解释和拟开展研究；未把新方法写成已验证的论文结果。

一、研究背景与问题

单细胞扰动预测模型尝试回答：改变某个基因，或对特定细胞施加一种药物后，基因表达会如何变化。实际使用时，预测模型会同时给出大量候选结果，而真实实验验证的预算有限。因此，除了提高表达预测精度，还需要判断哪些预测更可能出错、应优先复核。

本研究把已经训练好的扰动预测模型视为冻结的上游模型，以“任务—模型”为风险评价单位。一个任务包括细胞背景、扰动对象、扰动类型、剂量/时间等条件及匹配对照。SafeConf 接收其预测结果和预测时可获得的证据，估计任务级真实误差并分配复核优先级。

核心问题为：**在预测幅度已经解释相当部分误差的情况下，其他证据还能提供多少有效信息，怎样利用这些增量而避免质量混杂、重复计数和反馈泄漏？**

选择这个问题的依据来自已有实验。E201 显示预测幅度与误差存在强关联；E258/E259 显示历史效应的关联可能由测量质量解释；E273/E274 则提示模型历史反馈可能提供进一步线索。上述结果形成一个由已知规律逐步增加研究问题的过程。

二、国内外研究与本课题位置

现有相关方法可分为四种。

1. **扰动响应预测与内生不确定性。** PRESCRIBE 在扰动预测框架内联合处理模型与数据不确定性，主要针对未见基因扰动。它说明预测可靠性是明确的研究问题，但本课题关注冻结上游输出上的风险估计。[正式论文](#)
2. **后置误差估计。** PertEMA 的公开软件使用预测时特征、折外误差、梯度提升模型及后置校准。这使“用一个小模型预测另一个模型的误差”成为必须比较的近邻基线；其仓库说明跨新 screen 需重新拟合，且尚无配套论文。[官方软件](#)
3. **历史误差与校准。** HopCPT 在时间序列中检索相似历史误差状态并形成预测区间。由此，本课题的差异需要落实到扰动场景下的质量控制、残差反馈与冷启动验证。[正式论文](#)
4. **测量质量与评测混杂。** Systema 提醒扰动预测评价需分离系统性变化；2026 年扰动可靠性预印本进一步讨论实测数据质量对模型比较的影响。SafeConf 需要把预测器的错误、目标测量误差和历史测量支持分开。[Systema](#)、[可靠性预印本](#)

本课题拟解决的具体缺口是：**在幅度强基线、测量质量差异和有限反馈同时存在时，如何构造能逐项识别证据增量、缺少证据时可退化的后置风险估计器**。这是一项待检验的方法贡献；残差学习、经验贝叶斯和条件期望分解本身都是已有统计思想。

三、研究目标和拟回答的问题

3.1 总体目标

建立可作用于基因扰动和化学扰动预测输出的幅度锚定条件风险估计方法，在固定复核预算下识别更多高误差预测，并明确不同证据的适用条件。

3.2 三个研究问题

- **RQ1：幅度之外还剩什么？** 建立幅度基础风险后，支持度、测量稳定性和公共历史内容各自具有多大条件增量？
- **RQ2：如何从少量反馈学习剩余错误？** 用模型过去的合法预测错误修正幅度与历史仍未解释的部分，能否以较少反馈达到稳定的复核收益？
- **RQ3：这些规律能否跨类型成立？** 共享风险语义和处理流程，在基因与化学数据、不同上游模型和不同留出方式下检验增量，而非只看混合均值。

四、已有研究基础：证据怎样推出方法

4.1 E201：幅度决定基础风险的起点

已完成结果。 四背景、1,808 个主任务中，旧 SafeConf 与真实误差的 Spearman 相关为 0.4082，预测幅度为 0.6189；控制幅度后，旧分数的偏相关为 0.2503，95% 区间 [0.2021, 0.2980]。固定 20% 复核预算下，旧分数效用为 0.3200，幅度为 0.5943。

中间结论。 幅度是必须保留的强基线。其他证据有剩余关联，但直接混合可能损害排序。因此先估计幅度基础风险，再学习剩余误差。

不能推出。 幅度在所有模型和场景中必然单调决定误差；旧 SafeConf 已优于幅度；剩余关联必然是公共生物历史的独立作用。

依据：[E201 正式报告](#)。

4.2 E230/E234：历史值得检验，复杂结构尚无充分依据

已完成结果。 E230 固定预测并改变历史细胞/来源覆盖，完整历史组合相对幅度效用增加 0.011995，但预定开发门未通过。E234 的简单 M+H 增加 0.013928，基因簇区间 [-0.010165, 0.056283]；复杂历史候选 E232 比 M+H 只高 0.002832，区间同样跨零。

中间结论。 历史数量和内容需要分别检验；当前优先做简单可解释修正。M+H 的正点估计是候选线索。

下一实验。 在相同任务、误差、标签预算和历史池上，比较幅度、质量控制与历史内容修正，避免由来源数量带来表面收益。

依据：[E230](#)、[E234](#)。E201 的 pooled 效用与 E234 的背景宏平均不可直接横向比较。

4.3 E258/E259：质量 Q 必须先于历史内容 H

已完成结果。 Feng 开发数据中，原始历史离散度控制幅度后的宏偏相关为 0.572；增加来源细胞量控制后为 0.169；分半近似扣噪后为 0.008。E259 中，Feng 加入 H_raw 的效用增量为 -0.000206；Cui 加入完整 Q_split 后为 -0.003967；Lara ex vivo 为 -0.056071。

中间结论。 历史效应的原始相关不能被直接解释为生物信息。方法必须分别记录历史测量质量与效应内容，H 仅拟合在 M+Q 后的剩余误差。


机制边界。 split-half 包含采样波动和细胞异质性，属于测量稳定性代理，不等于精确识别纯技术噪声。Feng 与 Cui/Lara 的效用定义不同，以上差值不能跨研究平均。

依据：[E258 开发报告](#)、[E259](#)。

4.4 E273：各类证据应逐项配对，而不是只比较完整模型和 M

已完成复算。 本轮从已归档的 612 行 CPU 结果重新配对，得到 102 个有效冷折、21 个数据集—预测器单元。先平均折、再平均预测器、最后平均数据集组。

比较	平均效用差	正向数据集组	正向数据集—预测器均值
M → P	+0.133203	7/7	18/21
P → P+Q	+0.125287	6/7	16/21
P+Q → P+Q+H	+0.028091	5/7	16/21
P+Q+H → P+Q+H+E	+0.075886	6/7	16/21
P+Q → P+Q+E	+0.082070	6/7	19/21
P+Q+E → P+Q+E+H	+0.021907	3/7	11/21



E273 证据增量

新的中间结论。 H 在 E 之前和之后的增量不同。含 E 后的 H 增量主要受 McFarland 驱动；描述性留一数据集敏感性中，留出 McFarland 后宏增量为 -0.000974。McFarland 仍保留在主汇总中；该敏感性说明平均正数不足以证明每个分支普遍必要。

这里还缺什么。 E273 的 Q 只有背景相似度和扰动支持数，没有完整的来源细胞数/分半噪声控制。上游预测是否真正折外也尚未逐行证明。七个数据集组包含 McFarland 和 sci-Plex3 化学数据，Lara ex vivo/in vivo 还是相关研究分支，不能称为七个独立基因研究。

依据：[本轮复算与哈希](#)、[逐数据集增量](#)、[E273 状态](#)。旧 positive_cells 字段实际计数“至少一折正向”；上表改用单元均值的符号。

4.5 E274：反馈有价值的线索，冷启动需要独立定义

已完成结果。 模拟 E 记忆比例从 0% 到 100% 时，开发效用从 0.6795 到 0.7493；5% 和 10% 之间并不单调。GPU 重复表明小风险器可运行，但尚未证明新结构的独立收益。

本轮代码核对。 每个记忆预算都使用全部 fit 误差标签重新拟合风险器。所以该曲线衡量的是“完整监督下记忆特征稀疏化”，不是新模型零标签冷启动，也不是固定风险器只追加外部 memory。

架构选择。 提出对模型历史误差先去掉已解释成分，再按合法反馈数量向零收缩的校正。另做真正同反馈预算实验，才能把“反馈越多逐步适应”写成贡献。

依据：[E274 报告](#)、[E274 代码](#)。

五、拟研究方法

5.1 统一输入与误差对象

任务 q 的冻结预测效应为 p_q ，真实效应为 y_q ，共同基因轴为 G。主要误差 $e_q = \|p_q - y_q\|_2 / \sqrt{G}$ ，幅度 $M_q = \|p_q\|_2 / \sqrt{G}$ 。真实效应只用于合法反馈和最终评价，不能进入当前任务的风险输入。

证据依次为：预测幅度 M；测量与支持质量 Q；公共历史效应内容 H；同一上游版本过去的合法预测误差 E。其他预测侧特征 P 在基础风险比较中独立消融，防止把 P 的收益误算到 Q/H/E。

5.2 条件风险的递进表示

拟学习的风险为：

当前预测 → 幅度基础风险 $b(M)$

+ 测量质量修正 $\Delta Q(M, Q)$

+ 可选的历史内容修正 $\Delta H(M, Q, H)$

+ 有限反馈修正 $\Delta E(M, Q, H, E)$

↓

任务级期望误差与复核排序

每个修正使用前级的折外预测构造残差。H 若没有稳定增量，则令其修正为零；模型缺少合法 E 时令反馈修正为零。增量可正可负，因为证据可能表明当前预测比同幅度任务更可靠。

此处的“幅度锚定”指基础风险从 M 开始估计、其他来源解释其剩余误差。它不表示最终分数只能增加，也不表示幅度本身是误差下界。

5.3 有限反馈的收缩修正

对同模型的历史任务 j，保存折外残差 $r_j = e_j - \text{基础风险及已保留修正的折外预测}$ 。对当前任务的合法相似反馈计算加权残差均值，并按有效样本量收缩：

$\Delta E = [n_{\text{eff}} / (n_{\text{eff}} + \kappa)] \times \text{加权历史残差均值}$

无反馈时 $\Delta E=0$ ；少量反馈时避免用一两条错误大幅改写风险；更多同条件反馈支持较大的修正。 κ 仅用训练/内部验证确定。该形式可由高斯随机效应模型下的后验均值推导，详细假设及非独立记录处理见[方法推导](#)。

待检验价值。 相对直接输入历史平均错误，这一结构检验能否减少幅度/背景难度的重复计数，并提高少量反馈下的稳定性。若同信息简单模型表现相当，则采用更简单实现。

5.4 公共历史和错误记忆的不同职责

公共历史 H 描述其他合法背景/来源中观测到的扰动响应；E 描述某个冻结模型版本曾经错在哪里。前者包含实验真值但不含当前任务真值，后者必须有上游训练谱系和实际误差记录。二者不能互换，也不能因名称不同就假设统计独立。

5.5 理论目标

采用嵌套条件信息的风险估计观点，解释各级修正对应什么剩余信息；在明确随机效应假设下推导有限反馈的收缩形式；建立期望误差估计与固定预算复核收益的联系。

这些推导给出模型设计依据，不直接证明估计器在有限样本、分布变化时必然优于幅度或简单拼接。主要理论关系、证明和反例见[方法推导](#)。

六、拟创新点及对应验证

拟贡献	具体内容	必须出现的证据
幅度条件下的证据增量建模	将尺度、质量、历史内容、反馈分层，减少重复解释同一风险	同信息/同标签预算下超越幅度与普通拼接，或体现明确反馈效率收益
质量控制的残差反馈校正	对合法历史错误去除已解释成分，并按有效反馈量收缩	真正 0/少量/较多反馈曲线；优于原始错误均值、背景难度和普通收缩对照
跨扰动类型的可审计验证	基因/化学共享风险对象与处理语义，按类型和未见场景报告	合法 gene/chemical 线路、不同上游、按研究/扰动簇评价与负结果边界

单独的残差网络、模型门控、多数据集数量、标准恒等式以及软件接口，均不能替代上述贡献证据。

七、研究基础、可行性与主要风险

已有数据和实验足够支撑开题阶段：有四背景较强上游的正式结果、质量控制反例、多研究公开发表、计算资源与预测封存协议。这些资源分别承担规律发现、混杂诊断、候选方法开发和未来确认的职责。

现在最有价值的补充是将它们整理为同口径的证据链，并完成针对新方法的一轮公平比较。新增数据集不是当前首要任务。

主要风险及处理：H 的独立增量可能不成立，届时保留质量和反馈路线；E 可能主要记住背景平均难度，必须加入背景常数风险基线；化学任务键可能混合剂量/时间，先修合同；跨模型零反馈可能无法校准绝对误差，先只报告可验证的风险排序与支持范围。

八、研究进度与预期成果

8.1 30 日前的交付

- 28 日：完成证据链、E273 配对复算、数学推导、开题正文和汇报提纲。本目录为已完成交付。
- 29 日：按[实验计划](#)优先核验合法上游误差谱系，并在允许的开发数据上补一个幅度/质量/反馈的公平对照；若谱系不齐，以明确缺口和后续任务汇报，不制造“正式成功”。该实验尚未在本轮启动。
- 30 日：汇报已完成结果、拟研究模型与后续确认方案；学校模板、导师意见和最终汇报时长可据此调整。

8.2 开题后阶段

第一阶段闭合数据与双层折外合同；第二阶段比较简单基线与残差/反馈方法；第三阶段固定唯一候选，完成基因与化学确认、反馈预算和失效边界；第四阶段整理可复现方法论文。按每阶段的科学问题推进，不以增加实验编号作为完成标准。

8.3 预期成果与投稿方向

预期产出一套有明确数学对象、算法与条件增量实验的后置风险评估方法，以及可复算的软件和分类型评测材料。建议首先按 **IEEE Transactions on Computational Biology and Bioinformatics (TCBB)** 的计算方法论文组织；其正式范围包括由生物问题驱动的算法、数学、统计和计算方法。CCF 官方页面列 TCBB 为 B 类。[期刊范围](#)、[CCF 页面](#)

“二区”需要区分学校采用的中科院分区或 JCR 分类、年份与大小类；本报告不把 CCF-B 自动换算为二区。正式投稿准备程度以方法增量、比较公平性和验证完整性评估，录用由审稿决定。

九、汇报结论

现有工作已找到了一个可以继续深入的计算方法问题：预测幅度很强，而其他证据的价值取决于它是否解释了幅度、测量质量和已有反馈尚未解释的部分。基于此，本课题拟研究幅度锚定、质量控制和有限反馈收缩的条件风险估计方法。

现阶段能够成立的是这条研究问题和设计依据。后续用同信息、同预算、真实未见任务的实验决定最终模型的结构和论文主张。