


SafeConf 在做什么

不再是训练一个预测器，而是在预测之后做质检：真值未知时，哪些任务应优先复核。



打分可用：细胞 control 相似度、训练历史支持、冻结模型预测、模型分歧、predicted magnitude。

打分不可用：目标扰动后的真实表达。真值只用于事后评价，且必须在预测和分数封存之后打开。

今天要强化：分数对应明确预测器/家族的误差，不是模糊的“模型置信度”。